

Татьяна Перевощикова
Полина Черноморченко
Полина Машковцева
БКЛ-192

Car-review corpora

<http://carrevcorp.pythonanywhere.com/>
<https://github.com/pmashkovtseva/car-review-corpora>

О текстах и ходе работы

- Источник: [“Поясни за тачку”](#)
- Объем корпуса: 80126 токенов
- Первичный сбор данных: с помощью инструмента аналитики [Popsters](#)
- Обработка данных, чистка, токенизация, лемматизация с помощью [Natasha](#), создание базы данных
- Создание веб-приложения с помощью Flask
- Реализация алгоритма поиска с помощью Python
- Встраивание алгоритма поиска в веб-приложение
- Деплой на PythonAnywhere

Структура базы данных

1.

author_id	author
Фильтр	Фильтр
1	id226393308
2	id361554814
3	id11409697

2.

author_id	url_id	sentence_id	sentence
Фильтр	Фильтр	Фильтр	Фильтр
97	1	1	Что видят люди, глядя на эво...
97	1	2	Красивый, стильный, ...
97	1	3	Что видит фанат марки, ...

<http://carrevcorp.pythonanywhere.com/>

<https://github.com/pmashkovtseva/car-review-corpora>

Структура базы данных

3.

url_id	url
Филь...	Фильтр
1	https://vk.com/...
2	https://vk.com/...
3	https://vk.com/...

4.

sentence_id	word	lemma	pos
Фильтр	Фильтр	Фильтр	Фил...
1	что	что	PRON
1	видят	видеть	VERB
1	люди	человек	NOUN

searcher.py

1. Принимаем на вход данные;
2. Определяем, сколько в запросе элементов, и разделяем их;
3. Определяем, что ищем — все словоформы, конкретную словоформу, словоформу+тег, теги...
4. Лемматизируем при необходимости;
5. Подключаемся к БД и ищем нужные нам токены;
6. Выводим результаты; сообщаем, если результатов нет

Вопросы и решения

X: если под запрос попадают токены на стыке двух предложений, выводить оба или ни одного?

O: выводить оба.

Y: слово+POS — поиск по всем словоформам или только по данной?

O: по всем.

Z: а что с морфологической неоднозначностью?

O: у Natasha её нет :)

Примеры запросов

- данный+ADJ NOUN NOUN
- задний сиденье VERB
- колеса CCONJ
- “что” VERB машина+NOUN
- ...

Веб-приложение

это текстовый корпус обзоров на автомобили.

собиран в октябре 2021 года.

все материалы взяты из сообщества "Поясни за тачку".

[Поиск](#)[FAQ](#)[Список POS-тегов](#)[Контакты](#)

Ход работы

Таня — токенизация и лемматизация, создание БД, встраивание алгоритма поиска в веб-приложение

Полина Ч. — первичный сбор данных, реализация алгоритма поиска, деплой

Полина М. — разработка веб-приложения, презентация, деплой

Все — распределение заданий, тестирование, обсуждение ошибок и спорных случаев

Спасибо за внимание!

